# 복합 시계열 데이터 분석 및 예측을 자동화하는 MLOps 시스템

경희대학교 컴퓨터공학과 안영민 지도교수 허의남

# 목차

연구 소개


데이터 파이프라인

시계열 데이터 분석 및 처리

14 ML 모델 파이프라인

향후 연구 및 기타


### 더 나은 지능형 비즈니스를 위한 데이터 통합



### 더 스마트하게, 더 나은 가치를

빅데이터 시대 **비즈니스 차별성**은 데이터 통합으로 새로운 정보를 융합하는 능력

ΑI






### 10개 중 9개 조직이 AI 시스템을 비즈니스 핵심 기술로 전략

MIT Sloan Management, <a href="https://web-assets.bcg.com/1e/4f/925e66794465ad89953ff604b656/mit-bcg-expa">https://web-assets.bcg.com/1e/4f/925e66794465ad89953ff604b656/mit-bcg-expa</a> <a href="https://web-assets.bcg.com/1e/4f/925e66794465ad89953ff604b656/mit-bcg-expa</a> <a href="https://web-assets.bcg.com/1e/4f/925e66794465ad89953ff604b656/mit-bcg-expa</a> <a href="https://web-assets.bcg.com/1e/4f/925e66794465ad89953ff604b656/mit-bcg-expa</a> <a href="https://web-assets.bcg.com/1e/4f/925e66794465ad89953ff604b656/mit-bcg-expa</a> <a href="https://web-assets.bcg.com/1e/4f/925e66794465ad89953ff604b656/mit-bcg-expa</a> <a href="https://web-assets.bcg.com/1e/4f/925e66794465ad89953ff604b679466/mit-bcg-expa</a> <a href="https://

### ML 시스템 운영 과정에서 어려움




D Sculley et al, Hidden Technical Debt in Machine Learning System, NIPS, 2015

모델 개발은 빙산의 일각

반복적인 비즈니스 저해 요인

- 데이터 처리
- •모델 학습 및 검증
- 배포 및 운영

### 파이프라인을 자동화하는 MLOps 시스템



## 관련 연구



### 복합 시계열 데이터 분석

- Huaiyu Wan et al., CTS-LSTM: ..., Knowledge-Based Systems, 2020.
- Xingjian Shi et al., Convolutional LSTM Network: ..., NIPS, 2015.

### 한계

 복합 데이터로부터 얻을 수 있는 정보를 단지 신경망을 연결하는 방식으로 합하여 설명가능성이 떨어진다.



• 동일한 타임스탬프에 수집되는 시계열 데이터만을 가정한다.




### **MLOps & Automation**

- D Sculley et al, Hidden Technical Debt in Machine Learning System, NIPS, 2015
- Lukas Tuggener, Automated Machine Learning in Practice: ..., Ada, 2019

### 한계

• 이론적인 내용들이 주를 이루며, 다양한 툴을 결합한 단일 통합 솔루션에 대한 명확한 해법을 얻기는 어렵다.



제안 연구

# 가치

# TARGET 01

수치형 시계열 데이터 회귀 예측 모델링



다양한 시계열 분석 및 예측 애플리케이션에 적용

# TARGET 02

자동화된 MLOps 파이프라인



반복적인 비즈니스 저해 요인 탈피


# TARGET 03

수평적 확장 용이한 설계




탄력적 분석 인프라 제공

# 제안 연구




# 데이터 파이프라인



**Automated Pipeline** 

## 데이터 추출


#### KAFKA ARCHITECTURE



**▲** Kafka Architecture



▲ REST API로 Connector 간편 등록




▲ Kafka Connector를 이용한 싱크 자동화

```
<mark>root</mark>@master:/home/kafka-sparkhu/confluent-6.2.2# bin/kafka-console-consumer --topic=h
appycom source SENSOR DATA VIEW --bootstrap-server=localhost:9092 --from-beginning
schema":{"type":"struct","fields":[{"type":"int64","optional":false,"field":"ss id'{
},{"type":"float","optional":false,"field":"rstart"},{"type":"float","optional":false
 ,"field":"rlev1"},{"type":"float","optional":false,"field":"rlev2"},{"type":"float",
optional":false, "field": "rlev3"}, {"type": "float", "optional":false, "field": "rlev4"}, {
type":"float", "optional":true, "field":"rlev5"}, {"type":"float", "optional":true, "field
sational", "type":"float","optional":true,"field":"rlev7"},{"type":"float","optional":
":true,"field":"rlev8"},{"type":"float","optional":false,"field":"rend"},{"type":"int
64", "optional": false, "name": "org.apache.kafka.connect.data.Timestamp", "version": 1, "fi
eld": "event time"},{"type": "float", "optional":true, "field": "input data"},{"type": "str
ing", "optional": false, "field": "position"}, {"type": "string", "optional": false, "field":
type name"},{"type":"string","optional":true,"field":"unit"}],"optional":false,"name
:"SENSOR DATA VIEW"},"payload":{"ss id":2,"rstart":0.0,"rlev1":700.0,"rlev2":800.0,"r
lev3":1000.0, "rlev4":1500.0, "rlev5":0.0, "rlev6":0.0, "rlev7":0.0, "rlev8":0.0, "rend":20
000.0, "event time":1669102545000, "input data":460.0, "position": "광주A", "type name": "C
02", "unit": "ppm"}}
```

▲ JSON 데이터 교환 표준 형식으로 실시간 데이터 추출


### 데이터 레이크




```
ce_SENSOR_DATA_VIEW/year=2022/month=04
ce_SENSOR_DATA_VIEW/year=2022/month=05
ce_SENSOR_DATA_VIEW/year=2022/month=06
ce_SENSOR_DATA_VIEW/year=2022/month=07
ce_SENSOR_DATA_VIEW/year=2022/month=08
ce_SENSOR_DATA_VIEW/year=2022/month=10
ce_SENSOR_DATA_VIEW/year=2022/month=11
eter-tuning-task# hdfs dfs -ls /data/raw/happy
ce_SENSOR_DATA_VIEW/year=2022/month=11/day=01
ce_SENSOR_DATA_VIEW/year=2022/month=11/day=02
ce_SENSOR_DATA_VIEW/year=2022/month=11/day=03
ce_SENSOR_DATA_VIEW/year=2022/month=11/day=04
ce_SENSOR_DATA_VIEW/year=2022/month=11/day=05
ce_SENSOR_DATA_VIEW/year=2022/month=11/day=05
ce_SENSOR_DATA_VIEW/year=2022/month=11/day=06
```

▲ 데이터 레이크에 파티션되어 저장된 데이터

# 데이터 레이크




▲ 데이터 보존 관리 서비스




▲ 데이터 보존 관리 서비스 패키지 다이어그램


### 메타데이터 관리



### ▲ Metadata Synchronizer Class Diagram



▲ upsert\_metadata Sequence Diagram



▲ 문서 형태로 MongoDB에 저장된 metadata

# 시계열 데이터 분석 및 전처리



Schema Validation

Timestamp Validation

# Data Cleaning

Deduplication

Missing Value Processing

**Anomaly Value Processing** 

# Data Analysis

Univariate Analysis


Multivariate Analysis

...

# Data Transformation

Data Scailing

Windowing




### 매일 증분하는 데이터

-> 주기적 처리 능력 자동화 필요


다양한 시계열로부터 오는 빅데이터

-> 분산 처리 필요

# 아파치 스파크를 이용한 분산 처리, 아파치 하이브 데이터 웨어하우스



# 기술적 통계 및 중복 제거



#### Density Curve 0.012 mean: 440.985 ---- input\_data mode: 434.0 0.01 Q1: 403.0 Q2(median): 431.0 0.008 Q3: 458.0 skewness: 8.421 kurtosis: 104.832 0.006 coefficient of variation: 0.203 0.004 0.002 500 1000 2000 1500

Timestamp	Co2
2022-05-01 00:05:49	390.0
2022-05-01 00:15:49	389.0
2022-05-01 00:15:49	389.0
2022-05-01 00:25:49	396.0

# 정규성 분석 (주기 추정)

대부분 시계열 데이터 활용 알고리즘은 정기적으로 수집된 데이터를 가정

주기는 중요한 정보

### Clustering and Approximated GCD


Algorithm 1. Cluster and Approximated GCD

**Input**: time series dataframe *TS* 

*DiffTs* = Calc new dataframe with lagged timediff *TS[timestamp]* 

ClusteredTS = Cluster DiffTs[timestamp]

Superperiod = Approximated GCD (Top 95% mode diff ClusterTS)



<타임스탬프 간격 도출>

<클러스터링된 타임스탬프 격차>

<상위 95% 그룹 최빈값들의 근사된 최대공배수>

# 데이터 정제 (결측치 검출)

### ❖ Divide and Round

- 1. 정렬된 시계열 데이터의 이웃한 타임스탬프간 차이를 나열
- 2. 해당 타임스탬프 차이를 앞서 구한 주기로 구분
- 3. 나눠진 값을 반올림하여 해당 구간 내에 표시되지 않은 결측치의 개수를 추정

1	추정된 개수만큼 결측치를 표시	
4.	우성된 계구인금 얼룩시달 표시	

Timestamp	Co2
2022-05-01 00:05:49	390.0
2022-05-01 00:15:49	389.0
2022-05-01 00:45:49	389.0
2022-05-01 00:25:49	396.0

num of Missing values = Round([45:49 – 15:49] / 10:00) – 1 = **2** 

추정된 결측치


Timestamp	Co2
2022-05-01 00:05:49	390.0
2022-05-01 00:15:49	389.0
2022-05-01 00:25:49	N/A
2022-05-01 00:35:49	N/A
2022-05-01 00:45:49	389.0
2022-05-01 00:25:49	396.0


# 데이터 정제 (결측치 처리)




[결측치 처리 알고리즘에 따른 결측치 예측 성능 비교]


# 데이터 정제 (노이즈 검출)





# 데이터 정제 (노이즈 처리)








[노이즈 검출 기법에 따른 검출 결과]


Anomaly processing	RMSE	MAE	MAPE
		LSTM	
No processing	0.8867	0.5924	10.32
Drop out	0.5939	0.4984	8.68
Replace with min/max	0.5784	0.4672	8.41
EMA(smoothing)	0.3513	0.1815	4.79

[노이즈 처리 기법에 따른 예측 성능]


# 시계열 분해




[관측]



# 샘플링




## Airflow를 통한 주기적 수행






[DAG]


# 시계열 분석 라이브러리



# ML 모델 파이프라인



## 하이퍼파라미터 탐색 - AutoML





Difficulty to search hyperparameters..

AutoML with Ray tune!

# 하이퍼파라미터 탐색 - AutoML

#### **Tune Status**

Current time: 2022-12-05 15:19:32 Running for: 00:09:48.53

> Memory: 8.8/31.2 GiB

#### System Info

Using FIFO scheduling algorithm.

Resources requested: 4.0/4 CPUs, 0/0 GPUs, 0.0/15.6 GiB heap, 0.0/6.98 GiB objects (0.0/2.0 \_reserved, 0.0/1.0 \_mxnet\_worker, 0.0/1.0 \_mxnet\_server)

#### Messages

... 14 more trials not shown (8 PENDING, 6 TERMINATED)

#### **Trial Status**

Trial name	status		loc	hidden_size	Ir	num_layers	iter	total time (s)	best_mse	mse
train_func_69a20_00014	RUNNING	163.180	:20142	8	0.00105133	3				
train_func_69a20_00015	RUNNING	163.180	:20074	16	0.0689328	3				
train_func_69a20_00016	RUNNING	163.180	:19936	32	0.0162598	3				
train_func_69a20_00017	RUNNING	163.180	:20141	64	0.0638407	3				
train_func_69a20_00018	PENDING			2	0.0686572	4				
train_func_69a20_00019	PENDING			4	0.00810866	4				
train_func_69a20_00020	PENDING			8	0.0525651	4				
train_func_69a20_00021	PENDING			16	0.0264697	4				
train_func_69a20_00022	PENDING			32	0.00103617	4				
train_func_69a20_00023	PENDING			64	0.0401975	4				
train_func_69a20_00024	PENDING			2	0.00423307	5				
train_func_69a20_00025	PENDING			4	0.00103699	5				
train_func_69a20_00000	TERMINATED	163.180	:19936	2	0.0010417	1	1	69.993	0.00353771	0.00353771
train_func_69a20_00001	TERMINATED	163.180	:20074	4	0.099259	1	1	94.3297	0.00412781	0.00412781
train_func_69a20_00002	TERMINATED	163.180	:20141	8	0.00551675	1	1	70.74	0.00422874	0.00422874
train_func_69a20_00003	TERMINATED	163.180	:20142	16	0.00673473	1	1	74.9543	0.00402848	0.00402848
train_func_69a20_00004	TERMINATED	163.180	:19936	32	0.0567423	1	1	74.4295	0.0045467	0.0045467
train_func_69a20_00005	TERMINATED	163.180	:20141	64	0.00515913	1	1	78.1486	0.00415297	0.00415297
train_func_69a20_00006	TERMINATED	163.180	:20142	2	0.00392652	2	1	130.156	0.00412261	0.00412261
train_func_69a20_00007	TERMINATED	163.180	:20074	4	0.0066329	2	1	127.054	0.00418443	0.00418443

"hidden\_size": hp.grid\_search([2, 4, 8, 16, 32, 64]),

"|r": hp.loguniform(0.001, 0.1), "num\_layers": hp.grid\_search([1, 2, 3, 4, 5])

[search space]

경희대학교 컴퓨터공학과 안영민

search\_space = {

[AutoML hyperparameter estimating]

## 향후 연구



시계열 데이터를 뛰어넘어 이미지, 청각 등 멀티모달 데이터를 융합하는 MLOps 확장 엣지 및 코어를 활용한 분산 클라우드에서 효율적인 빅데이터 파티셔닝 및 연합학습

# 참조문헌

- [1] F. Castanedo, "A review of data fusion techniques," in ScientificWorldJournal, vol. 2013, 2013.
- [2] D. L. Hall and J. Llinas, "An introduction to multisensor data fusion," in *Proceedings of the IEEE*, vol. 85, 1997.
- [3] H. Widiputra, R. Pears, N. Kasabov, "Multiple Time-Series Prediction through Multiple Time-Series Relationships Profiling and Clustered Recurring Trends," In *Advances in Knowledge Discovery and Data Mining*, *PAKDD 2011*, 2011.
- [4] G. Gürses-Tran and M. Antonello, "Advances in Time Series Forecasting Development for Power Systems' Operation with MLOps," in *Forecasting*, vol. 4, 2022.
- [5] J. Benesty, J. Chen, Y. Huang, I. Cohen, I. "Pearson Correlation Coefficient". In *Noise Reduction in Speech Processing*. Springer Topics in Signal Processing, vol. 2, 2009.
- [6] D. Sculley, et al. "Hidden Technical Debt in Machine Learning Systems," in NIPS, 2015.